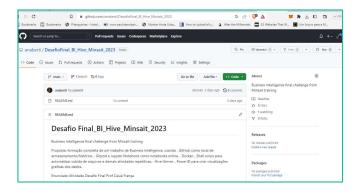
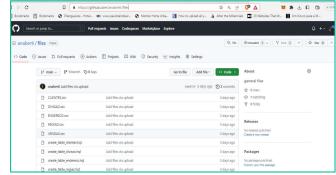
Etapas de Desenvolvimento do Desafio

1. Criação novo repositório no GitHub		2. Criação de repositório do GitHub para arquivos de fonte de dados		3. Criação de novo dashboard no gitpod		4. Clone da pasta bigdata_docker. Iniciar docker e hive		5. Criar diretórios e importar arquivos para dir de input		6. Criar pastas em hdfs e copiar para elas os arquivos de dados usando sh		7. Criar database e tabelas em beeline usando sh	
	8. Acessar Jupyter Notebook criar dataframes		9. Criar colunas de dia, mês, ano e quarter com base em invoice_date		10. Tratar campos brancos, nulos e Duplicados. Substituir pontos por vírgulas em numerais		11. Criar stage, colunas de consultas. Criar Fato e dimensões		12. Salvar dfs no hdfs		13. Download dos arquivos do gitpod		14. Upload das dfs no PowerBI
		15. 2º tratame transformaç dos dados		16. Testes I	Bi e Jupyter	17. Montagem Dashboard		18. Salvar arquivos na pasta para entrega zip e Github					

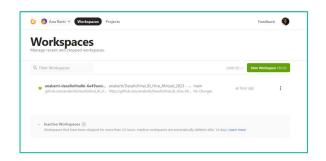
Preparo de ambientes – etapas 1 a 4



1. Criação novo repositório no GitHub https://github.com/anaberti/DesafioFinal_BI_Hive_Minsait_2023



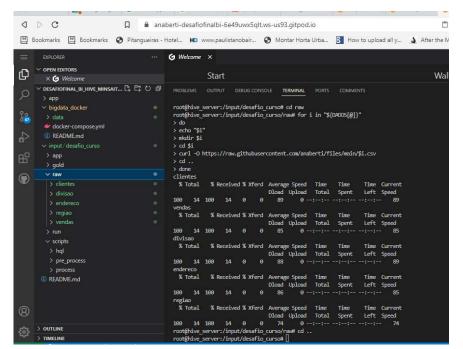
 Criação de repositório do GitHub para arquivos de fonte de dados https://github.com/anaberti/files



3. Criação de novo dashboard no gitpod

4. Clone da pasta bigdata_docker e iniciar docker e hive

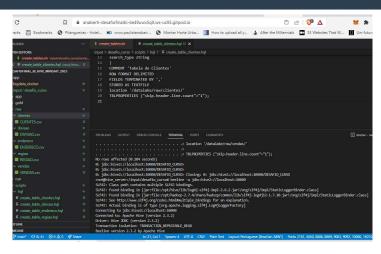
Preparo de diretorios e arquivos – etapas 5 a 7



```
# Cria estrutura de diretorios do desafio
mkdir desafio_curso
cd desafio curso
#!/bin/bash
PASTAS=("app" "gold" "raw" "run" "scripts")
for i in "${PASTAS[@]}"
do
echo "i"
mkdir $i
done
# Cria demais subdiretorios
#!/bin/bash
cd scripts
mkdir pre_process
mkdir process
mkdir hql
cd hql
TABELAS = ("clientes" "vendas" "divisao" "endereco" "regiao")
for i in "${TABELAS[@]}"
curl -O https://raw.githubusercontent.com/anaberti/files/
main/$create_table_$i.hql
done
cd ..
cd ..
```

```
# importa os arquivos .csv
DADOS=("clientes" "vendas" "divisao" "endereco" "regiao")
#!bin/bash
cd raw
for i in "${DADOS[@]}"
do
echo "$i"
mkdir $i
cd $i
https://raw.githubusercontent.com/anaberti/files/main/$i.csv
done
cd ..
# Transferência arquivos para hdfs
cd raw
DADOS=("clientes" "vendas" "divisao" "endereco" "regiao")
for i in "${DADOS[@]}"
echo "$i"
cd $i
hdfs dfs -mkdir -p /datalake/raw/$i
hdfs dfs -copyFromLocal $i.csv /datalake/raw/$i
cd..
done
```

Preparo de diretorios e arquivos – etapas 5 a 7



#!/bin/bash

Cria e usa database

beeline -u jdbc:hive2://localhost:10000 -e 'create database if not exists DESAFIO_CURSO;' beeline -u jdbc:hive2://localhost:10000 -e 'use DESAFIO_CURSO;'

Criacao tabelas

DADOS=("CLIENTES" "VENDAS" "DIVISAO" "ENDERECO" "REGIAO")

for i in "\${DADOS[@]}"

do

 $beeline - u jdbc: hive 2: // local host: 10000 - f/DESAFIO_CURSO ../../input/desafio_curso/scripts/hql/create_table_\$i.hql/desafio_curso/scripts/hql/desafio_curso/scr$

Trabalhando os dados – stage e dimensões – 8 a 13

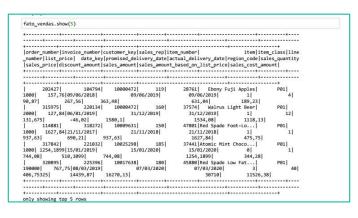
```
In [19]:

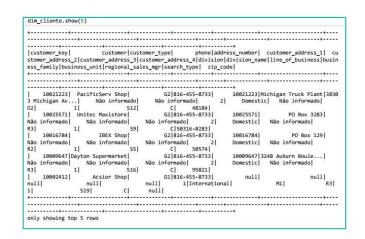
dim_local = df_stage.select("city", "country", "state", "region_code", "region_name").distinct()

In [28]:

dim_local.show(5)

| city|country|state|region_code|region_name|
| Morton| US| IL| 4| Central|
| Maxwell| US| CA| 1| Western|
| Meridian| US| MS| 2| Southern|
|St Louis Park| US| MN| 4| Central|
| Houston| US| TX| 2| Southern|
```

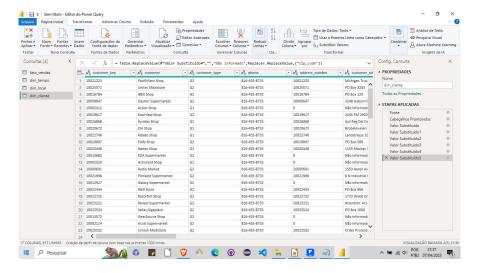




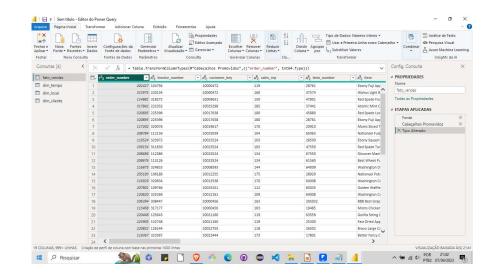
| In [23]:
| dim_tempo = df_stage.select("date_key", "invoice_date", "invoice_day", "invoice_month", "invoice_year", "quarter")
| In [24]:
| dim_tempo.show(5)
date_key	invoice_date	invoice_day	invoice_month	invoice_year	quarter
23/04/2018	25/04/2018	25	04	2018	2
11/05/2018	13/05/2018	13	05	2018	2
01(02/2019	03/02/2019	03	02	2019	1
31/12/2017	02/01/2018	02	01	2018	1
08/09/2017	10/09/2017	10	09	2017	3
only showing top 5 rows					

Conforme demonstrado em proccess.py

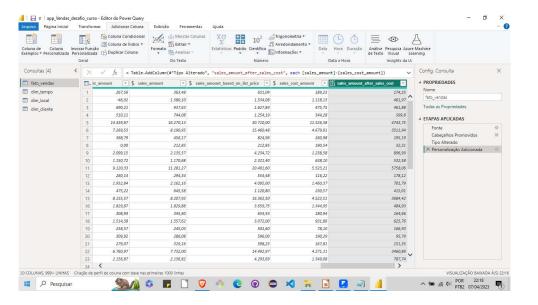
Dados carregados no Power Bi, corrigindo campos que por algum motivo ainda apresentaram problemas



Alterando os tipos dos dados



Acrescentando colunas e medidas interessantes para a análise dos dados



Na fato_vendas:

- sales_amount_after_sales_costs (valor de venda após custos = lucro)
- discount_percentage

Nova tabela medidas:

- total de vendas
- lucro total
- tícket médio

••

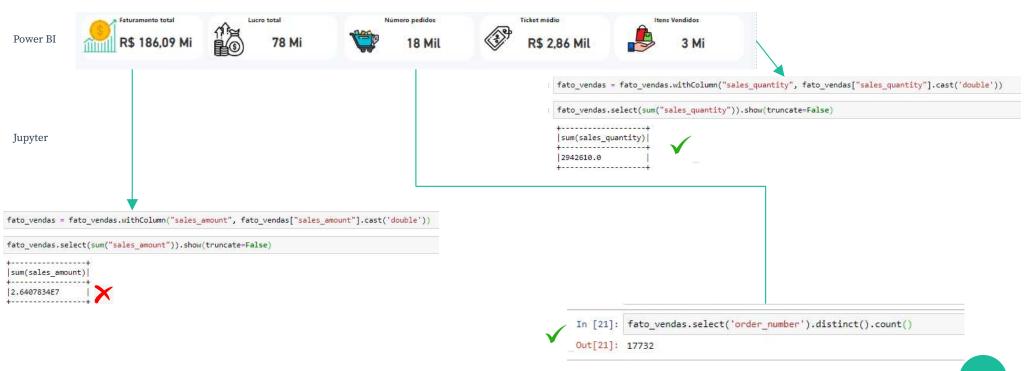
∨ 🖫 @Tab	elaMedidas
	Lucro_total
	Número_pedid
	Ticket_medio
	Vendas_totais



Montando layout do dashboard



Testando os resultados dos cálculos do Power BI x Jupyter





Montando layout do dashboard

